


04 三项成本与未使用预算的分配

幂成本；所有色块均以给定预算为分母，保留支持上限造成的未使用部分



左侧：预算 FLOPs · 上下文 Token；右侧为总预算使用率，不是各项成本占比。
最高预算的灰色部分主要来自 N、D 支持上限；不可行状态不解释为零成本。