

中国研究生数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

本文研究有限算力约束下大语言模型参数规模、训练数据量、数据质量与领域配比的配置问题。当前整体论文为协作初稿：第一问已基于附件 A 的真实质量信号和配比实验给出质量域评分、指标冲突描述与跨规模配比效应检验；第二至四问的正式结论待各负责人验收后填入。摘要中的统一预测、最优配置及能力外推数值暂不填写，以免将尚未完成的结果写成事实。

关键词： 数据质量 数据配比 标度律 资源配置 能力预测

目录

1	问题重述与总体思路	4
2	模型假设、数据与符号	4
3	问题一：数据质量评价与训练数据配比效应	4
3.1	问题分析与可识别性边界	4
3.2	A 侧综合质量代理	5
3.2.1	列表字段压缩与稳健标准化	5
3.2.2	指标方向的确定	5
3.2.3	综合代理的定义与边界	6
3.2.4	指标冲突与扩展集复核	7
3.3	17 域配比与目标域 Loss 的关系	8
3.3.1	组成约束与逐目标域 Ridge	8
3.3.2	13 维 Loss 向量与训练域-验证域作用矩阵	9
3.3.3	多维 Loss 的决策层：标量化、鲁棒性与能力保护	10
3.3.4	文献函数形式与本题主代理的关系	11
3.3.5	冻结代理后的跨实验组排序验证	11
3.3.6	绝对 Loss 迁移的反证性诊断	12
3.3.7	A12-A15 的使用边界	14
3.4	Q1 向后续问题的严格接口	14
3.5	本问结论与局限	14
4	问题二：广义标度律	15
5	问题三：给定算力预算的配置优化	15
5.1	目标函数、约束与边际替代关系	15
5.2	数值求解、支持域与结构转移诊断	15
5.2.1	求解流程与上游门禁	15
5.2.2	$N-D$ 解析诊断与连续预算相位	15
5.2.3	质量成本函数的几何性质	16
5.2.4	配比代理的优化选择验证	17
5.2.5	多起点求解与 KKT 验证	17

目录	3
6 问题四：能力指标与外推评估	18
7 模型评价与结论	18
参考文献	18

1 问题重述与总体思路

题目围绕参数规模 N 、训练数据量 D 、质量 Q 与领域配比 p 的关系，要求建立损失预测、预算优化与能力评测的衔接。四问依次涉及附件 A 的质量和配比、附件 B 的标度律、预算配置，以及附件 C 的下游能力预测。本文把四问的输出作为带单位、适用范围和不确定性的接口逐级传递；不同附件中的同名变量在缺乏成对标定时不视作同一数值坐标。

2 模型假设、数据与符号

当前已核实的基础约定是：训练配比满足 $p_j \geq 0$ 且 $\sum_{j=1}^{17} p_j = 1$ ；附件 A 的 10B、70B Loss 属于估计/外推值；跨附件 Loss 和质量坐标需单独检验可比性。

表 2.1 本文核心符号（待各负责人补齐单位和有效范围）

符号	含义	当前状态
N	模型参数规模	B 侧定义待 cyj 整合
D	训练数据量	B 侧定义待 cyj 整合
Q_z	A 侧派生质量评分	chm 的描述性指标
Q_{score}	B 附件原生质量字段	半合成实验字段
p	17 域训练配比	chm 接口已定义
L	交叉熵损失	各附件目标需核对

3 问题一：数据质量评价与训练数据配比效应

3.1 问题分析与可识别性边界

问题一包含两类由附件 A 直接支持的任务：一是利用 A1–A3 的 22 维质量信号评价七个语料域并分析指标冲突；二是利用 A4–A15 的 17 维训练配比与 13 个目标验证域交叉熵 Loss，分析训练配方与目标域 Loss 的关系。两类数据的域体系并不一一对应，因此本文分别建立 A 侧综合质量代理与逐目标域配比代理，再通过 A16 的映射类型和显式接口向后续问题传递结果，不人为补造跨附件数值关系。

A1 含 51,230 条质量记录；A2、A3 分别给出 arxiv 的 17,523 条和 github 的 203,752 条扩展记录。A4+A5 是 512 组 1M 配方及对应的 13 维 Loss；A6+A7、A8+A9、A10+A11 分别为 1M、60M、1B 检验组；A12–A15 在数据说明中明确属于 estimated/extrapolated，只用于压力测试。配比表和 Loss 表均按 index 一一对应。

需要特别限定的是，A4–A15 的配比表只给出 17 个比例，Loss 表只给出 13 个目标域 Loss；与这些配方实验相对应的训练数据量 D 并未作为字段提供。模型规模 1M、60M、1B 仅由不同实验文件组标识。因此第一问可以检验“小模型配比代理在不同实验组上的排序

是否保持”，但不能仅凭附件 A 识别连续的 $N-D$ 标度律，也不能把三个离散实验组拟合成普适的配比尺度衰减函数。基于这一可识别性边界，A6–A11 在本问中只承担冻结模型后的 held-out 验证，不再用于拟合额外的跨规模参数。

3.2 A 侧综合质量代理

3.2.1 列表字段压缩与稳健标准化

A1–A3 提供 22 个质量信号，其中 14 个为标量，8 个为列表字段。根据 SlimPajama-Meta-rater 公开数据卡 [1]，二分类字段 `ad_en` 与 `fluency_en` 的两个元素为 logits，本文以 softmax 后的正类概率保留连续置信信息；四个 ModernBERT 字段是 0–5 六等级 logits，以期望等级压缩；`qurater` 的四个评分分量取均值；`fineweb_edu` 取唯一元素。`argmax` 压缩保留为敏感性方案，而不与主方案混用。

计数型指标先作 $\log(1+x)$ 变换，DSIR 三项作 signed-log 变换。不同指标量纲和尾部分布差异较大，因此仅用 A1 估计中心与尺度，采用 median–MAD 稳健标准化：

$$z_{ij} = \text{clip}\left(\frac{x_{ij} - \text{median}(x_j)}{1.4826 \text{ MAD}(x_j)}, -5, 5\right). \quad (3.1)$$

其中 i 表示记录， j 表示指标。A2、A3 复用 A1 的变换、中心和尺度，避免扩展集信息反向进入评分口径。

3.2.2 指标方向的确定

八个模型评分字段的语义可以由数据卡直接确定为“数值越大，目标质量属性越强”，因此其方向固定为正。将这八项稳健标准化值的可用项均值定义为语义锚点

$$A_i = \frac{1}{|\mathcal{M}_i|} \sum_{j \in \mathcal{M}_i} z_{ij}, \quad (3.2)$$

其中 $\mathcal{M}_i$ 为记录 i 上非缺失的模型评分字段集合。

对于其余 14 个统计型指标，数据本身并不给出统一的“越大越好/越小越好”真值，因此不依据字段名称主观设定符号，而是在 A1 的每个质量域 d 内计算

$$\rho_{jd} = \rho_s(z_{ij}, A_i \mid i \in d), \quad (3.3)$$

并用 Fisher 变换汇总域内相关：

$$\bar{z}_j = \frac{\sum_d (n_{jd} - 3) \text{arctanh}(\rho_{jd})}{\sum_d (n_{jd} - 3)}, \quad \bar{\rho}_j = \tanh(\bar{z}_j). \quad (3.4)$$

指标方向取 $d_j = \text{sgn}(\bar{\rho}_j)$ ，再令 $z_{ij}^+ = d_j z_{ij}$ 。该步骤的含义仅是“将统计型指标与已知语义的模型评分锚点对齐”，并不能把锚点或其方向解释成客观质量真值。域间符号一致率及 leave-one-domain-out 方向稳定性同时保留为敏感性证据。

3.2.3 综合代理的定义与边界

题目附件没有提供样本级“真实质量”标签，因此质量标量不能由监督学习唯一识别。本文采用最小附加假设的分组等权复合指标：RPS/Natural、DSIR、model-based 三个指标家族先在组内对可用项等权，再在三组之间等权。对记录 i ，令

$$G_{ig} = \frac{1}{|\mathcal{J}_{ig}|} \sum_{j \in \mathcal{J}_{ig}} z_{ij}^+, \quad S_i = \frac{1}{3} \sum_{g \in \{\text{RPS}, \text{DSIR}, \text{MODEL}\}} G_{ig}, \quad (3.5)$$

其中 $\mathcal{J}_{ig}$ 是记录 i 在家族 g 中的非缺失指标集合。进一步用 A1 全体记录的均值和标准差定义 A 侧综合质量代理

$$Q_{A,i} = \frac{S_i - \mu_{S,A1}}{\sigma_{S,A1}}. \quad (3.6)$$

式 (3.5)–(3.6) 是透明的复合指标定义，而不是由附件识别出的唯一“真实质量函数”。分组等权的理由只是避免某个指标家族因字段数量更多而自动获得更大总权重，因此必须与 22 指标完全等权、列表 `argmax` 压缩和家族删除方案同时做敏感性检验。

域级主统计量采用 Q_A 中位数；固定评分规则下的记录 `bootstrap` 给出条件区间。结果见表 3.2。

表 3.2 A1 七个质量域的综合质量代理

质量域	样本数	Q_A 中位数	条件 95% 区间
arxiv	1419	2.6826	[2.6518, 2.7084]
book	171	2.7711	[2.6735, 2.8086]
c4	10000	-0.2173	[-0.2376, -0.1997]
commoncrawl	9640	0.5061	[0.4923, 0.5224]
github	10000	-0.5171	[-0.5438, -0.4886]
stackexchange	10000	0.1874	[0.1723, 0.2025]
wikipedia	10000	-0.3759	[-0.4003, -0.3473]

主方案与 `argmax` 压缩、22 指标完全等权方案的七域排名 `Spearman` 均为 0.9643，但分别发生 `github/wikipedia` 与 `book/arxiv` 的相邻次序交换。进一步删除 RPS 家族后，七域排名 `Spearman` 降至 0.8214，且 4 个域改变名次。因此图 3.1 中的窄 `bootstrap` 区间只量化固定评分规则下的记录抽样误差，不能替代评分规则不确定性。




图 3.1 七域综合质量代理的中位数与条件区间。横轴为 A1 内部标准化坐标，不是附件 B 的原始 Q_{score} 。

3.2.4 指标冲突与扩展集复核

指标冲突不再引入额外的人造“冲突强度函数”，而直接使用标准的 Spearman 秩相关。对方向统一后的任意两指标 j 、 r ，在质量域 d 内计算

$$\rho_{jr,d} = \rho_S(z_{ij}^+, z_{ir}^+ | i \in d). \quad (3.7)$$

若 $\rho_{jr,d} < 0$ ，表示在该域中两指标对样本的相对排序方向相反；只有在多个域或扩展数据中重复出现时，才将其视为稳定的描述性冲突。当前尚未完成全部相关系数的区间估计和多重比较校正，因此论文不使用“显著冲突”这一表述。

A1 的 1419 条 arxiv 和 10000 条 github 记录均包含于对应扩展集，故 A2/A3 不能直接称为独立验证。剔除重叠后，另有 arxiv 16104 条和 github 193752 条记录可用于复核。冻结 A1 的全部处理参数后，非重叠记录的 Q_A 中位数分别为 2.7146 和 -0.5363，与 A1 的 2.6826 和 -0.5171 接近。

进一步对全部 $\binom{22}{2=231}$ 个指标对做复制性核对：arxiv 在 A1 中有 96 个负相关指标对，其中 92 个在完整 A2 与去重 A2 中仍保持负相关，复制率为 95.83%；github 在 A1 中有 91 个负相关指标对，91 个在完整 A3 与去重 A3 中均保持负相关，复制率为 100%。两域共有 56 个指标对同时满足“sample / extended / non-overlap 三层均为负”。最稳定的共同冲突为大写字母行占比与终止标点行占比，其六个相关系数中最小绝对值仍为 0.7393。该结果说明若干负相关不是由 A1 与扩展集样本重叠单独造成，但由于尚未补充逐指标对 bootstrap 区间与多重比较校正，本文仍只将其称为“稳定复现的负相关”，而不使用“统计显著冲突”的表述。代表性结果见表 3.3。

表 3.3 A2/A3 非重叠记录中的代表性指标冲突

域	方向统一后的指标对（简写）	Spearman
arxiv	大写字母行占比 / 终止标点行占比	-0.8195
arxiv	DSIR wiki / 非字母词占比	-0.6303
github	大写字母行占比 / 终止标点行占比	-0.7442
github	词汇唯一率 / 高频三元字符占比	-0.4902

3.3 17 域配比与目标域 Loss 的关系

3.3.1 组成约束与逐目标域 Ridge

A4 的每一行是 17 个训练域比例。由于原始 CSV 的三位小数舍入会使行和轻微偏离 1，建模前按行归一化，记

$$\mathbf{p}_i = (p_{i1}, \dots, p_{i,17})^\top, \quad p_{ij} \geq 0, \quad \mathbf{1}^\top \mathbf{p}_i = 1. \quad (3.8)$$

A5 提供同一 index 下的 13 个目标验证域 Loss。不同目标域的 Loss 水平和波动尺度不同，因此不把 13 个原始 Loss 先求算术平均，而对每个目标域 k 单独拟合。

以 A4 归一化配方的均值为参考配方

$$\mathbf{p}_{\text{ref}} = \frac{1}{512} \sum_{i=1}^{512} \mathbf{p}_i, \quad (3.9)$$

则 $\mathbf{q}_i = \mathbf{p}_i - \mathbf{p}_{\text{ref}}$ 满足 $\mathbf{1}^\top \mathbf{q}_i = 0$ 。在该 16 维单纯形切空间内，使用 L2 正则线性回归 [2]：

$$(\hat{\alpha}_k, \hat{\beta}_k) = \arg \min_{\alpha, \beta} \left\{ \sum_{i=1}^{512} [L_{ik} - \alpha - \beta^\top (\mathbf{p}_i - \mathbf{p}_{\text{ref}})]^2 + \lambda_k \|\beta\|_2^2 \right\}, \quad \text{s.t. } \mathbf{1}^\top \beta = 0. \quad (3.10)$$

λ_k 仅在 A4+A5 的 512 条记录内通过 5 折交叉验证，从既定网格中选择；A6–A15 均不参与调参。

约束 $\mathbf{1}^\top \beta = 0$ 不是额外经验假设，而是组成数据的规范化表示。因为对任意常数 c ，

$$(\beta + c\mathbf{1})^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}) = \beta^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}),$$

故只有系数之间的对比可识别；零和约束选取其中唯一的最小范数表示。当前实现先在精确归一化单纯形上拟合 Ridge，再将等价系数表示平移为零和形式，预测值保持不变。

由式 (3.10) 得到 1M 配比代理

$$\hat{L}_{k,1M}(\mathbf{p}) = \hat{\alpha}_k + \hat{\beta}_k^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (3.11)$$

定义相对参考配方的配比效应

$$m_k(\mathbf{p}) = \widehat{L}_{k,1M}(\mathbf{p}) - \widehat{L}_{k,1M}(\mathbf{p}_{\text{ref}}) = \widehat{\beta}_k^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (3.12)$$

因此 $m_k < 0$ 表示在 A4+A5 的 1M 目标域坐标上，代理预测的 Loss 低于参考配方； $m_k > 0$ 则相反。该量只属于 A 侧 1M 目标域 Loss 坐标，不自动具有 60M、1B 或附件 B 的 Loss 单位。

组成约束也给出系数的正确解释。若从训练域 r 向训练域 j 转移比例 δ ，即 $\mathbf{p}' = \mathbf{p} + \delta \mathbf{e}_j - \delta \mathbf{e}_r$ ，则线性代理给出

$$m_k(\mathbf{p}') - m_k(\mathbf{p}) = \delta(\widehat{\beta}_{k,j} - \widehat{\beta}_{k,r}). \quad (3.13)$$

因此可解释的是“两个域之间重新分配”的系数差，而不是单独提高某一域比例的因果效应。

3.3.2 13 维 Loss 向量与训练域-验证域作用矩阵

已有文献对多域 Loss 的标准处理并不是先把各域 Loss 压缩成一个标量，而是先逐验证域建模，再在决策层按任务需求聚合。Data Mixing Laws 将第 k 个验证域 Loss 写为训练配比的函数，并以训练域-验证域系数刻画跨域作用；BiMix 同样先保留逐域 Loss，再在配比约束下求解整体目标；DoReMi 则从最坏域 excess loss 出发构造鲁棒目标 [3, 4, 5]。本文不直接照搬这些论文的函数形式，而只采用与附件 A 数据结构一致的“逐维建模-向量决策”框架。

将 13 个逐域 Ridge 联立，定义

$$\widehat{L}_{1M}(\mathbf{p}) = \widehat{\alpha} + \mathbf{B}(\mathbf{p} - \mathbf{p}_{\text{ref}}), \quad \mathbf{B} = [\widehat{\beta}_{k,j}] \in \mathbb{R}^{13 \times 17}, \quad (3.14)$$

其中第 k 行对应一个验证域，第 j 列对应一个训练域。相对于参考配方的 13 维效应向量为

$$\mathbf{m}(\mathbf{p}) = \widehat{L}_{1M}(\mathbf{p}) - \widehat{L}_{1M}(\mathbf{p}_{\text{ref}}) = \mathbf{B}(\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (3.15)$$

因此 $\mathbf{B}$ 是本文线性代理下的训练域-验证域作用矩阵。需要强调的是， $\widehat{\beta}_{k,j}$ 本身仍是组成数据上的相对对比系数；严格可识别的两域重新分配效应仍由式 (3.13) 中的系数差给出。

为比较不同验证域的作用模式而不改变模型本身，热力图只对每一行作显示归一化

$$\widetilde{B}_{k,j} = \frac{\widehat{\beta}_{k,j}}{\max_r |\widehat{\beta}_{k,r}|}. \quad (3.16)$$

该归一化只用于可视化，不进入任何预测或优化计算。参照 Data Mixing Laws 对训练域–验证域作用矩阵的展示方式 [3]，本文的 $\tilde{\mathbf{B}}$ 只用于比较同一验证域内各训练域的相对作用模式；其数值来自本题 A4+A5 的 Ridge，而不是该文的指数混合律。

3.3.3 多维 Loss 的决策层：标量化、鲁棒性与能力保护

式 (3.15) 保留了 13 个目标域的信息，因此“怎样得到一个配比方案”应由决策目标决定，而不是预先把 13 个原始 Loss 强行平均。为避免线性代理在未观测的单纯形顶点上外推，本文将第一问的配比决策限制在 A4 已观测配方的凸包

$$\mathcal{P}_A = \text{conv}\{\mathbf{p}_1, \dots, \mathbf{p}_{512}\}. \quad (3.17)$$

任意 $\mathbf{p} \in \mathcal{P}_A$ 均可写为 $\mathbf{p} = \sum_{i=1}^{512} \omega_i \mathbf{p}_i$ ，其中 $\omega_i \geq 0$ 、 $\sum_i \omega_i = 1$ 。这一定义只使用题目已给的 A4 配方支持域，不额外规定人为上下界。

若后续任务给出 13 个验证域的重要性权重 $\mathbf{s} \in \Delta^{12}$ ，则可按 Data Mixing Laws 的域聚合思想定义

$$J_{\mathbf{s}}(\mathbf{p}) = \sum_{k=1}^{13} s_k m_k(\mathbf{p}) = \mathbf{s}^\top \mathbf{B}(\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (3.18)$$

权重的来源严格分三种情况：若题目或下游任务给出验证域组成，直接采用已知权重；若没有任何偏好信息，可令 $s_k = 1/13$ 作为“各能力等权”的对称情景；只有在另有总体 validation Loss 与 13 个域 Loss 的成对观测时，才有数据基础学习 $\mathbf{s}$ 。附件 A 没有总体 Loss 字段，因此本文不从 A1–A16 中反推一组所谓“最优权重”。

若目标是避免某一能力域成为短板，可借鉴 DoReMi 的 worst-case excess-loss 思想，在本文参考配方坐标下定义

$$\min_{\mathbf{p} \in \mathcal{P}_A} \max_{k=1, \dots, 13} m_k(\mathbf{p}). \quad (3.19)$$

这里使用的是相对于同一参考配方的 Loss 增量，而非直接比较 13 个域的原始 Loss 绝对值；该式是本文基于已拟合代理构造的鲁棒决策准则，并不等同于重新实现 DoReMi 的在线 Group DRO 训练算法。

若任务更强调某个目标域 q ，同时要求其他能力不明显退化，则写成

$$\begin{aligned} \min_{\mathbf{p} \in \mathcal{P}_A} \quad & m_q(\mathbf{p}), \\ \text{s.t.} \quad & m_k(\mathbf{p}) \leq \varepsilon_k, \quad k \in \mathcal{K}_{\text{protect}}. \end{aligned} \quad (3.20)$$

阈值 ε_k 必须由题目要求、业务容忍度或独立估计的不确定性给出；附件 A 本身没有这些阈值，因此第一问只给出约束形式，不人为指定数值。

更一般地，问题可保留为 13 目标向量优化

$$\min_{\mathbf{p} \in \mathcal{P}_A} \mathbf{m}(\mathbf{p}) = \min_{\mathbf{p} \in \mathcal{P}_A} (m_1(\mathbf{p}), \dots, m_{13}(\mathbf{p}))^\top, \quad (3.21)$$

其解集按 Pareto 支配关系定义。改变式 (3.18) 中的 $\mathbf{s}$ ，或改变式 (3.20) 中的保护集合与阈值，可以扫描不同能力偏好下的可接受配方。BiMix 的约束配比求解提供了“先建立逐域 Loss，再在 $\sum_j p_j = 1$ 下数值优化”的文献范式；但 BiMix 还显式依赖训练步数/数据量，而附件 A 没有相应 D 字段，因此本文只借鉴其向量约束优化思想，不采用其双变量 Loss 律。

上述几种决策口径互不替代：式 (3.18) 回答“平均偏好”，式 (3.19) 回答“最坏能力保护”，式 (3.20) 回答“重点能力提升且不破坏保护域”，式 (3.21) 则保留全部多目标折衷。由于题目附件没有给出唯一的验证域权重或能力保护阈值，第一问不宣称存在一个由 A 数据唯一确定的“全局最优配比”。上述三个可标量化问题在 $\mathcal{P}_A$ 的凸组合坐标中均可写成线性规划，本文将对应可复现求解器实现于 `src/chm/q1_multiloss_decision.py`；权重与保护阈值均要求调用者显式提供，程序不自动生成。

3.3.4 文献函数形式与本题主代理的关系

Data Mixing Laws 在固定模型规模与训练步数下采用

$$L_k(\mathbf{p}) = c_k + a_k \exp \left(\sum_{j=1}^{17} t_{k,j} p_j \right) \quad (3.22)$$

描述逐验证域 Loss[3]。该式与本文 Ridge 的共同结构是“13 个验证域分别建模、共享同一 17 维配比输入”，但函数族不同。当前仓库中已完成并经过 A6–A11 检验的是 Ridge；尚未在相同五折协议和 held-out 集上完成式 (3.22) 的独立拟合比较。因此本文不因文献中存在指数形式就未经本题数据验证地替换主模型。后续若比较两种函数，必须固定同一 A4+A5 训练/调参划分，并仅用 A6–A11 比较泛化误差和排序相关后再决定主模型。

3.3.5 冻结代理后的跨实验组排序验证

问题一需要判断 A4+A5 学到的配方关系在附件提供的其他实验组中是否仍有信息。由于不同规模的绝对 Loss 水平明显变化，且附件 A 不提供与配方实验对应的 D ，验证指标采用只依赖排序的 Spearman 相关，而不拟合额外的尺度函数。对实验组 $\ell \in \{1M, 60M, 1B\}$ ，定义

$$\rho_{k,\ell}^{\text{pred}} = \rho_s \left(\widehat{L}_{k,1M}(\mathbf{p}_i^{(\ell)}), L_{ik}^{(\ell)} \right). \quad (3.23)$$

这里的 $\widehat{L}_{k,1M}$ 始终是由 A4+A5 冻结得到的同一代理；A6–A11 只用于一次性检验。

13 个目标域的结果见表 3.4。

表 3.4 13 个目标域的 held-out 配方排序相关

实验组	中位 Spearman	均值	最小值	最大值
1M	0.8381	0.8328	0.7446	0.9227
60M	0.8381	0.8314	0.7521	0.9202
1B	0.7067	0.7285	0.5691	0.8876




图 3.2 冻结的 1M Ridge 代理在三个真实检验组上的逐目标域排序表现。1B 使用不同的配方集合，因此其变化不能解释为纯参数规模效应。

A6 与 A8 使用完全相同的 256 条配方，因此还可以不依赖任何代理，直接比较两个实验组的真实 Loss 排序：

$$\rho_k^{1M \leftrightarrow 60M} = \rho_S(L_k^{1M}(\mathbf{p}_i), L_k^{60M}(\mathbf{p}_i)). \quad (3.24)$$

13 个目标域的相关范围为 0.9801–0.9980，中位数为 0.9944，见图 3.3。这只能说明在题目给定的这两组实验条件下，同一批配方的相对优劣高度稳定；由于 A 数据没有对应的 D 等训练控制变量，本文不把这种差异单独归因于参数量 N 。

A10 的 64 个 1B 配方与 A4/A6 的配方集合没有完全重复，因此 1B 的式 (3.23) 属于未见配方集合上的外部排序检验。它可以支持“1M 学到的配比排序仍保留部分信息”，但不能支持连续的 N 尺度传递。

3.3.6 绝对 Loss 迁移的反证性诊断

若直接把 A4+A5 的 1M 代理当作其他实验组的绝对 Loss 预测器，则尺度平移会显著影响 RMSE。删除全部配比变量、只使用 A4+A5 中该目标域的常数均值作为基线时，1M、




图 3.3 相同 256 条配方在 1M 与 60M 两个真实实验组中的 Loss 排序稳定性。

60M、1B 的 13 域 RMSE 中位数分别为 0.6759、1.4724、3.2514；完整 Ridge 分别为 0.4478、1.4450、3.2079。完整模型在 1M 和 60M 上分别有 13/13 个目标域的 RMSE 下降，但到 1B 只有 4/13 个目标域下降。




图 3.4 冻结 1M 配比代理相对于无配比常数基线的 RMSE 诊断。该图用于说明绝对 Loss 不能由附件 A 直接跨规模搬运，而非构造尺度律。

因此第一问的主要可验证结论是“配方排序具有迁移信息”，而不是“1M Loss 幅度可以按某个 N 的函数外推”。原先利用三个离散实验组拟合 $b_k(N)$ 和公共衰减指数 η 的做法不再进入主模型：A 数据既没有与配方实验对应的 D ，又只有三个模型规模位置，且 1B

的配方支持集与 1M/60M 不同，无法把斜率变化唯一归因于 N 。

3.3.7 A12–A15 的使用边界

A12–A15 的 10B/70B Loss 在数据说明中明确标记为 estimated/extrapolated，因此既不参与 Ridge 拟合，也不参与模型选择。两组使用相同的 63 个配方，且这 63 个配方均已出现在 A4 的 1M 训练配方集合中。附件给出的 10B 与 70B estimated Loss 在 13 个目标域中的直接 Spearman 范围为 0.9754–0.9965，中位数 0.9907；但冻结的 1M Ridge 在这两组 estimated Loss 上的 13 域 Spearman 中位数仅为 0.5136 和 0.4148。故 A12–A15 只作为附件内部的外推压力测试，不能作为真实大模型训练验证，也不能补足连续尺度识别。

3.4 Q1 向后续问题的严格接口

A16 中仅有 3 个 direct、3 个 near-direct 域映射，其余 11 个为 inferred，因此本文不生成 17 个看似精确的质量真值。第一问正式交付如下：

1. 七个质量域的 A 侧综合质量代理 Q_A 、条件抽样区间及评分规则敏感性。 Q_A 是描述性复合指标，不等于附件 B6–B8 的原生 Q_{score} 。
2. 17 维配比的 13 个目标域 1M Ridge 代理，以及式 (3.12) 定义的 target-specific 相对配比效应 $m_k(\mathbf{p})$ 。
3. A6–A11 给出的跨实验组排序验证和 A12–A15 的 estimated/extrapolated 压力测试。

附件 A 没有提供 $Q_A \leftrightarrow Q_{\text{score}}$ 的成对标定样本，也没有证明任一 Q1 目标域 Loss 与 B1 的 val_loss 属于同一数值坐标。因此第一问不提供 $Q_A \rightarrow Q_{\text{score}}$ 的数值映射，不把 $m_k(\mathbf{p})$ 直接加到 B1 Loss，也不提供由 A 数据拟合的 η 、 $b_k(N)$ 或其他连续尺度传递参数。 N 、 D 、B-native Q 与 Loss 的统一关系由问题二依据附件 B 独立建立；若后续需要把 $m_k(\mathbf{p})$ 映射到 B 侧 Loss，必须额外给出可验证的 Loss 坐标桥接证据。

3.5 本问结论与局限

在题目附件能够直接识别的范围内，问题一得到三点结论。第一，22 维质量信号可以构造透明的 A 侧综合质量代理，但其数值依赖明确的方向和权重假设，不能解释为客观质量真值；A2/A3 的非重叠记录支持 arxiv/github 域级结论在扩展样本上的稳定性，且多数负相关指标对在完整扩展与去重扩展中保持同号。第二，A4+A5 的逐目标域 Ridge 能在 held-out 1M、60M 和 1B 配方上保持明显的排序信息，其中 1M/60M 同配方真实 Loss 的中位 Spearman 为 0.9944。第三，绝对 Loss 的跨实验组误差和 1B 支持集变化表明，附件 A 不足以单独建立连续的配比尺度律。

因此，本问只输出“质量代理、配比相对效应、排序验证和映射边界”，把 N 、 D 与 B-native 质量坐标上的广义 Loss 建模严格留给问题二，从而使四问之间的递进关系与题目提供的数据保持一致。

4 问题二：广义标度律

本节预留给 cyj 的正式模型、参数、附件 B 验证和 Q/p 桥接检验。当前不能将附件 A 的 Q_z 与附件 B 的 Q_{score} 直接等同，也不能默认附件 A 的任一验证域 Loss 与 B1 的 val_loss 同尺度。

5 问题三：给定算力预算的配置优化

5.1 目标函数、约束与边际替代关系

本小节预留给 cyj，待问题二的预测器、单位和有效范围通过验证后填入。

5.2 数值求解、支持域与结构转移诊断

5.2.1 求解流程与上游门禁

第三问的数值求解不手工复制第二问参数，而通过版本化预测器调用。正式运行前检查预测器的 Loss 坐标、 $N/D/Q$ 适用域、质量变量状态、配比策略和不确定性。附件 A 的派生 Q_z 不要求被人为映射到附件 B 的 Q_{score} ；若使用连续质量变量，则正式预测器必须在同一 B-native Loss 坐标上验证 N, D, Q 。配比若无法建立跨 Loss 标定，则只作多目标域敏感性，不输出唯一配比。当前上游接口仍未满足正式门禁，因此本小节先报告求解器和支持域诊断，正式配置表在接口验收后统一生成。

5.2.2 N - D 解析诊断与连续预算相位

固定 $Q = Q_0$ 、 $p = p_{\text{ref}}$ 时，质量额外成本为零，题面成本化为

$$C_0(N, D; L_c) = (6 \times 10^{18} + 2 \times 10^{14} L_c) ND. \quad (5.25)$$

以第二问 B1 diagnostic 的

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta} \quad (5.26)$$

检查数值求解器。令

$$P = \frac{C_{\max}}{6 \times 10^{18} + 2 \times 10^{14} L_c}, \quad ND = P, \quad (5.27)$$

在不触边界时得到

$$N^* = \left(\frac{\alpha A}{\beta B} P^\beta \right)^{1/(\alpha+\beta)}, \quad D^* = \frac{P}{N^*}. \quad (5.28)$$

结合 B1 声明的 $N \in [0.070542, 11.965825]$ B、 $D \in [0.134, 299.893]$ B token，连续增加

预算时依次出现

$$N_{\min} \text{ bound} \rightarrow \text{interior} \rightarrow D_{\max} \text{ bound} \rightarrow (N_{\max}, D_{\max}) \text{ support corner.}$$

表 5.5 给出三个 C7 上下文情景的临界预算。

表 5.5 N - D 诊断模型的预算相位临界点

Context	$N_{\min}$ 释放	$D_{\max}$ 激活	支持域饱和
2048	7.95×10^{17}	9.33×10^{21}	2.30×10^{22}
8192	9.47×10^{17}	1.11×10^{22}	2.74×10^{22}
131072	3.99×10^{18}	4.69×10^{22}	1.16×10^{23}

注意力成本与基础训练成本之比具有简单形式

$$\frac{C_{\text{attn}}}{C_{\text{train}}} = \frac{L_c}{30000}. \quad (5.29)$$

因此 2048、8192、131072 Token 对应约 0.0683、0.2731、4.3691。题面三档预算中， 10^{19} FLOPs 的三个上下文均为内点； 10^{22} FLOPs、2048 Token 已触及 $D_{\max}$ ； 10^{24} FLOPs 的三个情景均到达 $N_{\max}, D_{\max}$ 。后者存在大量预算剩余，只能解释为 B1 支持域不足，不能解释为额外算力无效。

在解析临界点和三档预算上使用 25 起点数值优化交叉验证，最佳数值解与解析解的 Loss 最大绝对差约 4.44×10^{-16} ， N/D 最大相对误差约 4.23×10^{-8} ，说明相位变化来自活跃约束切换而非局部最优。

5.2.3 质量成本函数的几何性质

题面质量成本为

$$C_Q = 10^9 D [g(Q) - g(Q_0)]_+. \quad (5.30)$$

将其与训练和注意力成本比较， D 可约去：

$$\frac{C_Q}{C_{\text{train}} + C_{\text{attn}}} = \frac{g(Q) - g(Q_0)}{N (6 \times 10^9 + 2 \times 10^5 L_c)}. \quad (5.31)$$

故相同质量升级的相对成本随 N 按 $1/N$ 下降。等成本临界规模为

$$N_{\text{crit}} = \frac{g(Q) - g(Q_0)}{6 \times 10^9 + 2 \times 10^5 L_c}. \quad (5.32)$$

指数型和幂函数型 $g(Q)$ 为凸成本，而对数型为凹成本。又因正部函数存在， $Q = Q_0$ 处不光滑，左导数为 0，右导数为 $10^9 D g'(Q_0)$ ，数值求解中采用单侧 KKT 条件。

为比较量级，取诊断场景 $Q_0 = 0.5 \rightarrow Q = 1$ 、 $N = 1\text{B}$ ，得到表 5.6。这些比例只描述成本侧价格，并不代表提高质量后的净收益。

表 5.6 诊断场景下质量升级成本与基础计算成本之比

Context	指数型	幂函数型	对数型
2048	0.598	0.731	0.189
8192	0.502	0.614	0.159
131072	0.119	0.146	0.0376

5.2.4 配比代理的优化选择验证

为检验第一问配比代理是否可用于候选选择，严格保持 A4/A5 为拟合集，对 A6/A8/A10 的 held-out 配方选择预测 Loss 最低者，再由 A7/A9/A11 的真实目标域 Loss 评价其实际名次。表 5.7 给出全部 13 个目标域结果。

表 5.7 逐目标域配比代理的 held-out 选择能力

规模	精确选中真实最优	落入真实前 10%
1M	10/13	13/13
60M	8/13	13/13
1B	7/13	8/13

对 pile_cc、wikipedia_en、arxiv、stackexchange、github 五个主敏感性目标，共 15 次检验中 11 次精确选中真实最优，14 次进入真实前 10%。明显偏离发生在 1B pile_cc，其预测选择为实际第 10/64，相对最优 regret 约 2.63%。因此配比代理可用于受支持候选筛选，但 1B 已出现明显的目标域依赖失效风险。

同时，A4 训练支持内五个主目标域的最低预测候选最大单域占比中位数约 0.954，4/5 超过 0.9，存在极端化选择倾向。由于

$$m_k(\mathbf{p}) = \beta_k^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}) \quad (5.33)$$

是线性函数，当目标域固定且跨 Loss 系数为正时，正的尺度因子不会改变 $\mathbf{p}$ 的排序。故当前代理本身不能识别“预算增加引起最优配比支持集切换”，正式求解不采用无约束连续单纯形最优，而采用已观测/受支持候选与多目标域敏感性。

5.2.5 多起点求解与 KKT 验证

正式数值求解器将上游 Loss 抽象为 $L(N, D, Q)$ 及其梯度，并定义单位额外算力的边际收益

$$r_x = -\frac{\partial L / \partial x}{\partial C / \partial x}. \quad (5.34)$$

预算约束活跃且变量均为内点时，有

$$r_N = r_D = r_Q = \mu. \quad (5.35)$$

变量位于下界时要求 $r_x \leq \mu$ ，位于上界时要求 $r_x \geq \mu$ ； $Q = Q_0$ 使用质量成本右导数，预算未用满时由互补松弛得 $\mu = 0$ 。

当前仅以人工构造的单调质量收益进行软件验证，不将其最优配置作为赛题证据。generic solver 与 readiness policy 共 8 个单元测试通过；三类成本函数与 5 个测试预算组成的 15 个 KKT 点全部通过，自由变量边际比最大相对离散约 3.83×10^{-7} 。

6 问题四：能力指标与外推评估

本节预留给 zhh 的下游 Benchmark 桥接、历史验证、不确定性和情景预测。

7 模型评价与结论

当前仅第一问附件内经验结论完成初稿。总模型结论与建议应在第二至四问交付、跨附件接口验收后填写。

参考文献

- [1] OpenDataLab, SlimPajama-Meta-rater Dataset Card.
- [2] Liu Q, Zheng X, Muennighoff N, et al., RegMix: Data Mixture as Regression for Language Model Pre-training, International Conference on Learning Representations, 2025.
- [3] Ye J, Liu P, Sun T, et al., Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance, International Conference on Learning Representations, 2025.
- [4] Ge C, Ma Z, Chen D, et al., BiMix: A Bivariate Data Mixing Law for Language Model Pretraining, 2025.
- [5] Xie S M, Pham H, Dong X, et al., DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining, Advances in Neural Information Processing Systems, 2023.