

中国研究生数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

本文研究有限算力约束下大语言模型参数规模、训练数据量、数据质量与领域配比的配置问题。当前整体论文为协作初稿：第一问已基于附件 A 的真实质量信号和配比实验给出质量域评分、指标冲突描述与跨规模配比效应检验；第二至四问的正式结论待各负责人验收后填入。摘要中的统一预测、最优配置及能力外推数值暂不填写，以免将尚未完成的结果写成事实。

关键词： 数据质量 数据配比 标度律 资源配置 能力预测

目录

1	问题重述与总体思路	3
2	模型假设、数据与符号	3
3	问题一：数据质量评价与训练数据配比效应	3
3.1	问题分析与数据划分	3
3.2	多维质量评分	4
3.2.1	指标处理与方向统一	4
3.2.2	指标冲突与扩展集复核	5
3.3	逐目标域配比代理与跨规模检验	6
3.4	配比效应的经验尺度传递	7
3.5	消融、外推与接口边界	8
4	问题二：广义标度律	9
5	问题三：给定算力预算的配置优化	9
5.1	目标函数、约束与边际替代关系	9
5.2	数值求解与情景检验	9
6	问题四：能力指标与外推评估	9
7	模型评价与结论	9
	参考文献	9

1 问题重述与总体思路

题目围绕参数规模 N 、训练数据量 D 、质量 Q 与领域配比 p 的关系，要求建立损失预测、预算优化与能力评测的衔接。四问依次涉及附件 A 的质量和配比、附件 B 的标度律、预算配置，以及附件 C 的下游能力预测。本文把四问的输出作为带单位、适用范围和不确定性的接口逐级传递；不同附件中的同名变量在缺乏成对标定时不视作同一数值坐标。

2 模型假设、数据与符号

当前已核实的基础约定是：训练配比满足 $p_j \geq 0$ 且 $\sum_{j=1}^{17} p_j = 1$ ；附件 A 的 10B、70B Loss 属于估计/外推值；跨附件 Loss 和质量坐标需单独检验可比性。

表 2.1 本文核心符号（待各负责人补齐单位和有效范围）

符号	含义	当前状态
N	模型参数规模	B 侧定义待 cyj 整合
D	训练数据量	B 侧定义待 cyj 整合
Q_z	A 侧派生质量评分	chm 的描述性指标
Q_{score}	B 附件原生质量字段	半合成实验字段
p	17 域训练配比	chm 接口已定义
L	交叉熵损失	各附件目标需核对

3 问题一：数据质量评价与训练数据配比效应

3.1 问题分析与数据划分

问题一同时包含质量信号分析与训练配方实验。质量信号在七个语料域上提供 22 个指标，配方实验则以 17 个训练域比例为输入、13 个验证域交叉熵为输出。两组域并不一一对应，因此分别建立描述性质量评分与逐目标域配比代理，再通过显式接口交付后续问题，避免在第一问中人为制造跨附件数值对应。

附件 A1 含 51,230 条质量记录；A2、A3 分别提供 arxiv 的 17,523 条与 github 的 203,752 条扩展记录。A4、A5 含 512 条 1M 训练配方及对应 Loss，A6–A11 包含 1M、60M、1B 检验集。A12–A15 的 10B、70B Loss 在数据说明中属于 estimated/extrapolated，只作为压力测试。A16 是 17 个配方域到质量域的参考映射。所有配比按 index 与 Loss 对齐，原始表因小数舍入产生的行和偏差在建模前通过归一化消除。

3.2 多维质量评分

3.2.1 指标处理与方向统一

22 个指标包含 14 个标量和 8 个列表字段。根据公开数据卡 [1]，主方案对二分类 logits 使用正类 softmax 概率，对六等级 logits 使用期望等级，对四分量评分取均值；argmax 压缩作为敏感性方案。计数型指标先作 $\log(1+x)$ 变换，DSIR 三项作 signed-log 变换。仅用 A1 估计中心和尺度，得到

$$z_{ij} = \text{clip}\left(\frac{x_{ij} - \text{median}(x_j)}{1.4826 \text{MAD}(x_j)}, -5, 5\right). \quad (3.1)$$

A2、A3 复用这些参数，防止扩展集信息进入评分口径。八个模型评分型指标统一为越大越好的方向，构成方向锚点 $A_i = \frac{1}{8} \sum_{j \in \mathcal{M}} z_{ij}$ 。其余指标在各质量域内与 A_i 计算 Spearman 相关，再以 Fisher- z 按域样本量汇总相关符号；同时保留域间符号一致率，识别方向随领域改变的指标。

将指标按 RPS/Natural、DSIR、模型评分分为 11、3、8 项，先组内等权、再三组等权。对记录 i ，综合分数为

$$S_i = \frac{1}{3} \left(\frac{1}{11} \sum_{j \in \text{RPS}} z_{ij}^+ + \frac{1}{3} \sum_{j \in \text{DSIR}} z_{ij}^+ + \frac{1}{8} \sum_{j \in \text{MODEL}} z_{ij}^+ \right), \quad (3.2)$$

其中 z_{ij}^+ 是方向统一后的稳健标准化指标；具体计算对可用指标取均值。再使用 A1 总体均值和标准差把 S_i 转换为派生分数 $Q_{z,i}$ 。域级主统计量是 Q_z 的中位数，区间由固定评分规则下的记录 bootstrap 给出。

表 3.2 A1 七个质量域的派生评分（条件 95% 区间）

质量域	样本数	Q_z 中位数	条件 95% 区间
arxiv	1419	2.6826	[2.6518, 2.7084]
book	171	2.7711	[2.6735, 2.8086]
c4	10000	-0.2173	[-0.2376, -0.1997]
commoncrawl	9640	0.5061	[0.4923, 0.5224]
github	10000	-0.5171	[-0.5438, -0.4886]
stackexchange	10000	0.1874	[0.1723, 0.2025]
wikipedia	10000	-0.3759	[-0.4003, -0.3473]

表 3.2 与图 3.1 展示评分下的域间差异，不证明相应语料在任意训练任务上均有更高收益。argmax 压缩与 22 指标等权替代方案相对主方案的七域排名 Spearman 均为 0.9643，分别发生 github/wikipedia 与 book/arxiv 的相邻次序交换。删除 RPS 家族的消融则使排名 Spearman 降至 0.8214，四个域改变名次；因此记录 bootstrap 的窄区间不能代表评分规则不确定性。




图 3.1 七域质量评分的中位数与条件区间。横轴为 A1 标准化单位，不是附件 B 的原始 Q_{score} 。

3.2.2 指标冲突与扩展集复核

对指标 j ，不同域与方向锚点相关符号的不一致性可写为

$$H_j = 1 - \frac{|\sum_d w_d \text{sgn}(\rho_{jd})|}{\sum_d w_d}, \quad w_d = 1. \quad (3.3)$$

方向统一后，两指标在域 d 的连续冲突强度为 $C_{jk,d} = \max(0, -\rho_{jk,d})$ 。该定义用于排序而非显著性检验；相关区间及多重比较校正尚未完成。

A1 的 arxiv 1419 条和 github 10000 条样本 ID 全部包含于对应扩展集，故扩展集不能直接称为独立验证。剔除重叠后，另以 arxiv 16104 条和 github 193752 条记录复核，所得 Q_z 中位数分别为 2.7146 和 -0.5363，与 A1 的 2.6826 和 -0.5171 接近。表 3.3 给出非重叠记录中的代表性负相关，表内数值不作因果解释。

表 3.3 A2/A3 非重叠记录中的代表性指标冲突

域	方向统一后的指标对（简写）	Spearman
arxiv	大写字母行占比 / 终止标点行占比	-0.8195
arxiv	DSIR wiki / 非字母词占比	-0.6303
github	大写字母行占比 / 终止标点行占比	-0.7442
github	词汇唯一率 / 高频三元字符占比	-0.4902

3.3 逐目标域配比代理与跨规模检验

原始的 13 个目标域 Loss 水平和尺度不同，直接平均会掩盖域内配比结构。以 $\mathbf{p} = (p_1, \dots, p_{17})^\top$ 表示归一化训练配比，且 $p_j \geq 0$ 、 $\sum_j p_j = 1$ ，对目标验证域 k 分别拟合

$$\hat{L}_k(\mathbf{p}) = \beta_{0,k} + \sum_{j=1}^{17} \beta_{k,j} p_j. \quad (3.4)$$

Ridge 正则参数只在 A4+A5 的 512 条训练数据内通过确定性五折交叉验证选取；A6–A11 不参与调参。因单纯形闭合使带截距原始系数有整体平移不唯一性，报告参数时变换为 $\sum_j \beta_{k,j} = 0$ ，并相应调整截距，使预测不变。系数只表示相对于平均训练域的统计对比，不解释为独立因果效应。RegMix 的小模型加回归代理路线提供方法参照 [2]；以下数值全部来自本题附件的本地计算，不等同于该论文的公开基线。

表 3.4 13 个目标域的 held-out 配方排序相关

模型规模	中位 Spearman	均值	最小值	最大值
1M	0.8381	0.8328	0.7446	0.9227
60M	0.8381	0.8314	0.7521	0.9202
1B	0.7067	0.7285	0.5691	0.8876




图 3.2 Ridge 在三个模型规模上的逐目标域排序表现。1B 使用不同配方集合，不能将分布变化全归因于参数规模。

表 3.4 和图 3.2 表明小模型学到的配方排序在 held-out 数据上具有迁移信息，但 1B 的目标域异质性明显。A6 和 A8 使用完全相同的 256 条配方，直接比较真实 1M 与 60M Loss，不涉及代理模型，13 域 Spearman 范围为 0.9801–0.9980，中位数 0.9944，见图 3.3。1B 的 64 条配方与 train/test 1M 均无完全重复，因而是未见配方集合上的检验。




图 3.3 相同 256 条配方在 1M 与 60M 真实 Loss 上的直接排序稳定性。

3.4 配比效应的经验尺度传递

只保留配方方向不足以接入后续损失预测。固定 A4+A5 的代理 $s_k(\mathbf{p})$ 后，用 A6–A11 作后验校准：

$$L_k(N, \mathbf{p}) = a_k(N) + b_k(N)s_k(\mathbf{p}) + \varepsilon. \quad (3.5)$$

13 个目标域在三个真实规模的 $b_k(N)$ 均为正。以 A4 归一化配方的均值 $\mathbf{p}_{\text{ref}}$ 为参考，中心化配比效应为 $m_k(\mathbf{p}) = \beta_k^\top (\mathbf{p} - \mathbf{p}_{\text{ref}})$ ，使参考配方的修正为零，避免与后续基准 Loss 截距重复计数。

采用目标域固定效应模型 $\log b_k(N) = c_k - \eta \log(N/10^6) + \varepsilon_{k,N}$ ，得到 $\hat{\eta} = 0.1450$ 。按目标域重抽样 10000 次的 95% 区间为 [0.1069, 0.1867]；同时重抽目标域和校准配方的 2000 次有效 bootstrap 区间为 [0.0976, 0.2010]。两个区间均条件于已拟合的 A4+A5 Ridge。域特异 η_k 约在 0.0412–0.3074 之间。1M 和 60M 共享配方支持集，而 1B 使用另一组 64 条配方，故 η 可能混合规模变化和支持集差异，仅作经验传递参数，不称普适标度律。




图 3.4 13 个目标域的配比效应幅度与三个真实模型规模。10B/70B 估计数据未参与参数拟合。

3.5 消融、外推与接口边界

删除全部配比变量，仅用训练集目标域常数均值预测，1M、60M、1B 的 13 域 RMSE 中位数分别为 0.6759、1.4724、3.2514；完整 Ridge 分别为 0.4478、1.4450、3.2079。完整模型在前两种规模均改善 13/13 个目标域，在 1B 只改善 4/13。图 3.5 给出相对降幅，说明 1B 的排序信息不能被误写为可靠的绝对 Loss 预测。




图 3.5 完整配比代理相对无配比常数基线的 RMSE 中位数相对降幅，柱上为实际得到改善的目标域数量。

A12–A15 的 10B、70B 表只含估计/外推 Loss；两组相同的 63 条配方均在 1M 训练集中出现。因此其排序检验是已见配方上的附件估计值内部压力测试，不能充当真实大模型验证。A16 中仅有 3 个 direct、3 个 near-direct 域映射，其余 11 个为 inferred，不构造 17 个精确质量真值。第一问交付七个真实质量域的 Q_z 描述及不确定性、17 维配比的 13 个目标域响应。附件 B6–B8 的 Q_{score} 为官方文件中的半合成字段，但与 A 侧 Q_z 无成对数值标定；B1 的 `val_loss` 与本节 13 个 Loss 目标亦未证明可比。后续问题须分别在各自原生坐标建模，跨附件连接只在接口和证据确定后使用。

本节图表来自 `chm` 的固定版本汇总文件。质量区间仅反映固定评分规则下的记录抽样；RPS 家族删除敏感性、有限的三个真实规模、1B 配方支持集变化、跨附件质量与 Loss 坐标未识别，均应进入全文的不确定性分析。代码和输入哈希在 `chm` 交接记录、`outputs/chm/local_recheck_v1/` 与图表 `manifest` 中可追溯。

4 问题二：广义标度律

本节预留给 `cyj` 的正式模型、参数、附件 B 验证和 Q/p 桥接检验。当前不能将附件 A 的 Q_z 与附件 B 的 Q_{score} 直接等同，也不能默认附件 A 的任一验证域 Loss 与 B1 的 `val_loss` 同尺度。

5 问题三：给定算力预算的配置优化

5.1 目标函数、约束与边际替代关系

本小节预留给 `cyj`，待问题二的预测器、单位和有效范围通过验证后填入。

5.2 数值求解与情景检验

本小节预留给 `chm` 的预算优化求解、约束核验及敏感性结果；正式数值依赖 `cyj` 已验收的预测接口。

6 问题四：能力指标与外推评估

本节预留给 `zhz` 的下游 Benchmark 桥接、历史验证、不确定性和情景预测。

7 模型评价与结论

当前仅第一问附件内经验结论完成初稿。总模型结论与建议应在第二至四问交付、跨附件接口验收后填写。

参考文献

- [1] OpenDataLab, SlimPajama-Meta-rater Dataset Card.
- [2] Liu Q, Zheng X, Muennighoff N, et al., RegMix: Data Mixture as Regression for Language Model Pre-training, International Conference on Learning Representations, 2025.