

中国研究生数学建模竞赛

题 目： 问题一：数据质量评价、指标冲突与领域配比建模

摘 要：

针对题目附件 A 的质量信号和训练配比实验，本文建立逐文本与逐领域的质量代理，分析指标冲突，并构建 17 维配比到 13 个目标域交叉熵 Loss 的条件性决策模型。对 A1 的 51,230 条记录统一处理 22 个指标，按家族等权合成质量分数；冻结该规则后，对 A2/A3 全量扩展集及去重记录进行对照。以方向统一后的秩相关识别冲突，55 条显著负相关指标边在去重扩展集复现；采用综合质量与指标分歧的二维评价，标记需复核文本而不伪造人工质量真值。

对 A4+A5 的 512 个配方，本文逐目标拟合含 17 个主项与 10 个二元乘积项的交互代理。训练内嵌套五折比较中，交互模型在 13 个目标域的 RMSE 均低于线性 Ridge，目标域中位数分别为 0.4499 和 0.4921。A6–A11 用于同条件比较；这些组曾影响模型选择，不能视为全新盲测。在 A4 配方凸包内，采用 McCormick 松弛与空间分支定界计算等权、质量约束及最差域保护情景，四组浮点数值上下界间隙均小于 0.001。A12–A15 为估算外推表：交互代理与 10B、70B 估算 Loss 的排序相关中位数仅为 0.4915、0.3941，不能支持真实大模型的配方最优主张。最终答案是在明确权重、质量政策和支持范围内可复现的条件性配方决策。

关键词： 数据质量 指标冲突 领域配比 交互回归 多目标决策

目录

1 问题一：数据质量评价与训练数据配比效应	3
1.1 问题分析与可识别性边界	3
1.2 A 侧综合质量代理	3
1.2.1 列表字段压缩与稳健标准化	3
1.2.2 指标方向的确定	4
1.2.3 由 22 个指标到样本和领域质量	4
1.2.4 指标方向的跨领域稳健性	5
1.2.5 A2/A3 扩展集对照	5
1.2.6 指标冲突与扩展集复核	6
1.3 17 域配比与目标域 Loss 的关系	8
1.3.1 组成约束与逐目标域线性基线	8
1.3.2 13 维 Loss 向量与训练域–验证域作用矩阵	9
1.3.3 交互主模型与多目标配方决策	10
1.3.4 文献函数形式与本题主代理的关系	12
1.3.5 冻结代理后的跨实验组排序验证	12
1.3.6 绝对 Loss 迁移的反证性诊断	14
1.3.7 A12–A15 的使用边界	15
1.4 Q1 向后续问题的严格接口	16
1.5 本问结论与局限	16
参考文献	17

1 问题一：数据质量评价与训练数据配比效应

1.1 问题分析与可识别性边界

问题一包含两类由附件 A 直接支持的任务：一是利用 A1–A3 的 22 维质量信号评价七个语料域并分析指标冲突；二是利用 A4–A15 的 17 维训练配比与 13 个目标验证域交叉熵 Loss，分析训练配方与目标域 Loss 的关系。两类数据的域体系并不一一对应，因此本文分别建立 A 侧综合质量代理与逐目标域配比代理，再通过 A16 的映射类型和显式接口向后续问题传递结果，不人为补造跨附件数值关系。

A1 含 51,230 条质量记录；A2、A3 分别给出 arxiv 的 17,523 条和 github 的 203,752 条扩展记录。A4+A5 是 512 组 1M 配方及对应的 13 维 Loss；A6+A7、A8+A9、A10+A11 分别为 1M、60M、1B 检验组；A12–A15 在数据说明中明确属于 estimated/extrapolated，只用于压力测试。配比表和 Loss 表均按 index 一一对应。

需要特别限定的是，A4–A15 的配比表只给出 17 个比例，Loss 表只给出 13 个目标域 Loss；与这些配方实验相对应的训练数据量 D 并未作为字段提供。模型规模 1M、60M、1B 仅由不同实验文件组标识。因此第一问可以比较配比代理在不同实验组的排序，不能仅凭附件 A 识别连续的 N – D 标度律。A6–A11 不用于拟合额外的跨规模参数，但其比较结果曾参与交互模型形式的选择，不能称为最终完全未触碰的盲测。

1.2 A 侧综合质量代理

A1–A3 为每条文本提供 22 个量纲和含义不同的质量信号，却没有综合质量真值。本文先把列表压缩为标量，再在 A1 建立统一尺度和方向，形成可复现的描述性质量代理；由样本评分聚合为领域评分，最后用 A2/A3 全量扩展记录检验其迁移表现。该代理表示相对于 A1 的质量坐标，不能解释为客观质量标签。

1.2.1 列表字段压缩与稳健标准化

A1–A3 提供 22 个质量信号，其中 14 个为标量，8 个为列表字段。根据 SlimPajama-Meta-rater 公开数据卡 [1]，二分类字段 ad_en 与 fluency_en 的两个元素为 logits，本文以 softmax 后的正类概率保留连续置信信息；四个 ModernBERT 字段是 0–5 六等级 logits，以期望等级压缩；qurater 的四个评分分量取均值；fineweb_edu 取唯一元素。argmax 压缩保留为敏感性方案，而不与主方案混用。

计数型指标先作 $\log(1+x)$ 变换，DSIR 三项作 signed-log 变换。不同指标量纲和尾部分布差异较大，因此仅用 A1 估计中心与尺度，采用 median–MAD 稳健标准化：

$$z_{ij} = \text{clip}\left(\frac{x_{ij} - \text{median}(x_j)}{1.4826 \text{ MAD}(x_j)}, -5, 5\right). \quad (1.1)$$

其中 x_{ij} 指经过必要变换后的数值， i 表示记录， j 表示指标。中位数和 MAD 比均值和标准差更不易受极端文本影响；常数 1.4826 将正态分布下的 MAD 调整到近似标准差尺度，并非本题拟合参数。截断到 $[-5, 5]$ 避免极值主导后续均值；MAD 退化时依次回退到标准差和 1。A2、A3 完全复用 A1 的变换、中心和尺度，使三个数据集处于同一评价坐标。

1.2.2 指标方向的确定

八个模型型字段按其评分语义固定为正向。为给其余指标提供共同的方向参考，本文将这八项稳健标准化值在每条记录上的可用项均值定义为语义锚点：

$$A_i = \frac{1}{|\mathcal{M}_i|} \sum_{j \in \mathcal{M}_i} z_{ij}. \quad (1.2)$$

其中 $\mathcal{M}_i$ 为记录 i 上非缺失的模型型评分字段集合。 A_i 是本文构造的方向参考，不是附件提供的真实质量标签。列表的元素结构来自公开数据卡；softmax 正类概率、期望等级及 qurater 四维均值均属于本文的压缩选择。

对其余 14 个统计型字段，较大的原始数值未必代表较好质量；这里只需识别单调方向，因此在 A1 全部有效记录上计算秩相关，而不要求线性关系：

$$\rho_j = \rho_s(z_{ij}, A_i) = \text{Corr}(\text{rank } z_j, \text{rank } A). \quad (1.3)$$

若 $\rho_j \geq 0$ ，较大指标值通常对应较大语义锚点，取 $d_j = +1$ ；否则取 $d_j = -1$ 。统一后的值为

$$d_j = \begin{cases} +1, & j \text{ 为模型型字段, 或 } \rho_j \geq 0, \\ -1, & \rho_j < 0, \end{cases} \quad z_{ij}^+ = d_j z_{ij}. \quad (1.4)$$

相关系数只决定方向，不是指标权重或因果效应。即使 $|\rho_j|$ 接近零，主模型仍保留该质量信号；方向证据弱的问题由后文的稳健性诊断揭示。

1.2.3 由 22 个指标到样本和领域质量

22 个字段分属 RPS/Natural（11 项）、DSIR（3 项）和 model-based（8 项）。若直接对 22 项等权平均，RPS 会仅因字段较多而取得较大总权重。本文选择家族内等权、三个家族等权。令 $\mathcal{J}_{ig}$ 表示记录 i 在家族 g 中非缺失的指标集合，定义

$$G_{ig} = \frac{1}{|\mathcal{J}_{ig}|} \sum_{j \in \mathcal{J}_{ig}} z_{ij}^+, \quad S_i = \frac{1}{3} \sum_{g \in \{\text{RPS}, \text{DSIR}, \text{MODEL}\}} G_{ig}. \quad (1.5)$$

集合 $\mathcal{J}_{ig}$ 仅处理原始缺失值，不使用方向稳定性筛选。用 A1 全体 S_i 的均值 $\mu_{S,A1}$ 和标准差 $\sigma_{S,A1}$ 固定坐标：

$$Q_{A,i} = \frac{S_i - \mu_{S,A1}}{\sigma_{S,A1}}. \quad (1.6)$$

$Q_{A,i}$ 是一条文本的相对评分。题目还要求领域质量，因此对每个领域 d 的全部样本评分取中位数 $Q_{A,d} = \text{median}_{i \in d} Q_{A,i}$ 。中位数较少受长尾文本影响；10% 截尾均值为辅助统计。域内 bootstrap 95% 区间仅衡量固定评分规则下的样本抽样波动，不能覆盖方向和权重选择的不确定性。

1.2.4 指标方向的跨领域稳健性

主方向由全 A1 Spearman 决定。为判断它是否过度依赖某一领域，另算七个领域各自的 ρ_{jd} 、方向一致率，以及每次去掉一个领域后在其余全部记录上重算的 $\rho_j^{(-d)}$ 。若 LOO 翻号，该指标仍留在主 Q_A 中，但标注为方向脆弱。另设仅供压力测试的删除脆弱指标、22 项完全等权和列表 argmax 压缩方案，比较七域排序。上述诊断不改变主模型准入规则。

1.2.5 A2/A3 扩展集对照

A2/A3 的用途是检验 A1 评分规则能否迁移到更大的 arxiv/github 样本。两者复用 A1 的列表压缩、变换、median/MAD、方向及 Q_A 标准化参数，不重新拟合评价尺子。主结果使用 A2/A3 全部记录；剔除与 A1 重叠的记录只作为额外稳健性复核。表 1.1 和图 1.1 给出固定规则下的域级结果。

表 1.1 A1 七域质量评分：区间为固定评分规则下的条件 bootstrap 95% 区间

领域	样本数	$Q_{A,d}$	10% 截尾均值	排名	条件区间
book	171	2.9183	2.8308	1	[2.7879, 2.9606]
arxiv	1419	2.6887	2.7013	2	[2.6621, 2.7262]
commoncrawl	9640	0.4367	0.4576	3	[0.4224, 0.4543]
stackexchange	10000	0.2517	0.2550	4	[0.2370, 0.2660]
wikipedia	10000	-0.2944	-0.3216	5	[-0.3194, -0.2706]
c4	10000	-0.3040	-0.2999	6	[-0.3193, -0.2840]
github	10000	-0.4854	-0.5195	7	[-0.5117, -0.4602]

完整 A2 arxiv 的 $Q_{A,d}$ 为 2.7253，A3 github 为 -0.5055；去重后的对应中位数为 2.7279 与 -0.5063。主评分保留全部 22 项。五个统计指标在 LOO 中出现方向翻转，其中全局 $|\rho|$ 最小的是大写字母行占比（0.0283）和高频三元字符占比（0.0406）；这只说明相对于本文锚点的单调方向证据较弱。删除全部五个翻号指标的压力测试使七域排序 Spearman 降到 0.8929；22 项完全等权为 0.9643，argmax 压缩为 1.0000。固定规则下的窄区间因此不能代替方法选择的稳健性检验。

本轮另对 A1 按域固定分为 70% 方向训练集和 30% 排名评估集；前者分层重抽 100 次




图 1.1 七域质量评分及条件区间；横轴为 A1 内部标准化坐标。

并重估 14 个统计字段的符号，后者始终不用于该次符号拟合。100 次中七域排序及各字段符号均未变；但留一领域已有五字段翻号，且八种合理评分规则的排名范围为 **book/arxiv** 第 1–2、**c4/github** 第 5–7。因此将固定规则下的抽样区间与方法选择导致的排名包络分别报告，后者不称为 95% 置信区间。**book** 仅 171 条，尤其不能将评分当作外部质量真值。

1.2.6 指标冲突与扩展集复核

指标冲突不再引入额外的人造“冲突强度函数”，而直接使用标准的 Spearman 秩相关。对方向统一后的任意两指标 j 、 r ，在质量域 d 内计算

$$\rho_{jr,d} = \rho_S(z_{ij}^+, z_{ir}^+ \mid i \in d). \quad (1.7)$$

若 $\rho_{jr,d} < 0$ ，表示在该域中两指标对样本的相对排序方向相反。进一步在 A1 总体及各域、去重扩展集分别对 231 个指标对做 Spearman 检验，各检验家族分别以 Benjamini–Hochberg 法控制 FDR 为 0.05。将 A1 总体显著负相关且在 **arxiv** 或 **github** 去重扩展集也显著负相关的指标对定义为复制性显著冲突边；阈值和规则在计算前固定。

A1 的 1419 条 **arxiv** 和 10000 条 **github** 记录均包含于对应扩展集，故 A2/A3 不能直接称为独立验证。剔除重叠后，另有 **arxiv** 16104 条和 **github** 193752 条记录可用于复核。按冻结规则得到的非重叠中位数分别为 2.7279 和 -0.5063 ，与 A1 的 2.6887 和 -0.4854 接近。

进一步对全部 $\binom{22}{2=231}$ 个指标对做复制性核对：**arxiv** 在 A1 有 108 个负相关对，其中 102 个在完整 A2 与去重 A2 中仍为负；**github** 的 85 个 A1 负相关对全部在完整 A3 与去重 A3 中保持负向。两域共有 59 个指标对在 **sample**、**extended**、**non-overlap** 三层均为负。这些是描述性同号计数；按上述显著性规则，A1 总体有 66 对显著负相关，其中 55 对在去重

扩展集复现。代表性结果见表 1.2。

表 1.2 A2/A3 非重叠记录中的代表性指标冲突

域	方向统一后的指标对（简写）	Spearman
arxiv	DSIR wiki / 非字母词占比	-0.6303
arxiv	DSIR books / 非字母词占比	-0.6280
github	高频二元字符占比 / 高频三元字符占比	-0.5648
github	DSIR wiki / 大写字母行占比	-0.3908

冲突成因与冲突感知评价对复制性冲突边，比较总体与七个 A1 域内的相关系数及校正后的显著性。若多个域内仍显著负相关，记为跨域重复模式；若仅总体负相关，记为领域混合模式；仅少数域显著则记为领域依赖模式。这是观测数据的模式分类，不能证明因果取舍。专业性评分与平均词长的总体相关为 -0.4994 ，七个域内均显著负相关；高频二元、三元字符占比的总体相关为 -0.4844 ，七域内也均显著负相关。指标语义和定向仍需谨慎解释。对最强冲突边另比较去除双侧各 1% 极端值前后的相关，详见可复现结果表。

最强的 10 条边在同时去除两指标两侧各 1% 极端记录后仍全部为负；例如专业性评分与平均词长由 -0.4994 变为 -0.4990 ，主要负相关不能归因于少数极端值。原 $Q_{A,i}$ 仍是质量代理。令 $\mathcal{E}_c$ 为 55 条复制性冲突边，以总体相关绝对值为权重，定义同一样本的指标分歧度

$$D_i = \frac{\sum_{(j,k) \in \mathcal{E}_c(i)} |\rho_{jk}| |z_{ij}^+ - z_{ik}^+|}{\sum_{(j,k) \in \mathcal{E}_c(i)} |\rho_{jk}|}, \quad \mathcal{E}_c(i) = \{(j,k) \in \mathcal{E}_c : z_{ij}^+, z_{ik}^+ \text{ 均可用}\}. \quad (1.8)$$

无可用边时 D_i 记为缺失；主要评价结果是二维 $(Q_{A,i}, D_i)$ ，不将高分歧直接扣为低质量。A1 的 book、arxiv、github、c4、commoncrawl、wikipedia、stackexchange 七域 D 中位数分别为 2.580、2.292、1.999、1.903、1.512、1.471、1.202；去重扩展集中的 arxiv 和 github 分别为 2.332 和 2.003。四象限以 A1 的 Q_A 与 D 中位数划分，全指标标准差作为敏感性对照。 Q_A 和 D 均为附件 A 坐标中的代理，不直接等同于 B 侧质量评分。

冲突后的处理与原文核查冻结 A1 的 Q_A 中位数 0.0273 和 D 第 75 百分位 2.0423。 D 高于阈值的记录进入复核标记，不直接减去质量分；低 Q_A 只标记低优先级，不自动剔除。无可用冲突边时 D 记缺失并触发复核，不伪装为零。A1 的保留、保留并复核、低优先级、低优先级并复核分别有 20384、5231、18038、7577 条；冻结阈值在去重 arxiv/github 扩展集的复核触发率分别为 69.04% 和 47.08%，说明阈值跨域触发率有明显变化。按域及 (Q, D) 四象限固定哈希抽取 27 条，逐条以 ID、原始行号和内容 SHA 回读原文而不发布全文。arxiv 的一条低 Q 高 D 记录主要含 $\text{\LaTeX}$ 宏定义，提示格式冲突；book 的一条高 Q 高 D 记录以版权信息开头且极长，提示高评分也需结构审查；c4 的低 Q 低 D 公告文本有明确事务信

息，提示低分歧、低综合分不等于无使用价值。这些只是可复核案例，不是独立人工标签，也不能给出分类准确率。55 条边在 A1 选择并在去重 A2/A3 复制；各范围分别做 FDR 校正，不声称最终边集具有联合 5% FDR 保证。

1.3 17 域配比与目标域 Loss 的关系

1.3.1 组成约束与逐目标域线性基线

A4 的每一行是 17 个训练域比例。由于原始 CSV 的三位小数舍入会使行和轻微偏离 1，建模前按行归一化，记

$$\mathbf{p}_i = (p_{i1}, \dots, p_{i,17})^\top, \quad p_{ij} \geq 0, \quad \mathbf{1}^\top \mathbf{p}_i = 1. \quad (1.9)$$

A5 提供同一 index 下的 13 个目标验证域 Loss。不同目标域的 Loss 水平和波动尺度不同，因此不把 13 个原始 Loss 先求算术平均，而对每个目标域 k 单独拟合。下述 Ridge 用作可解释的线性对照，正式配比预测在后文的二阶交互主模型中给出。

以 A4 归一化配方的均值为参考配方

$$\mathbf{p}_{\text{ref}} = \frac{1}{512} \sum_{i=1}^{512} \mathbf{p}_i, \quad (1.10)$$

则 $\mathbf{q}_i = \mathbf{p}_i - \mathbf{p}_{\text{ref}}$ 满足 $\mathbf{1}^\top \mathbf{q}_i = 0$ 。在该 16 维单纯形切空间内，使用 L2 正则线性回归 [2]：

$$(\hat{\alpha}_k, \hat{\beta}_k) = \arg \min_{\alpha, \beta} \left\{ \sum_{i=1}^{512} [L_{ik} - \alpha - \beta^\top (\mathbf{p}_i - \mathbf{p}_{\text{ref}})]^2 + \lambda_k \|\beta\|_2^2 \right\}, \quad \text{s.t. } \mathbf{1}^\top \beta = 0. \quad (1.11)$$

λ_k 仅在 A4+A5 的 512 条记录内通过 5 折交叉验证，从既定网格中选择；A6–A15 均不参与调参。

约束 $\mathbf{1}^\top \beta = 0$ 不是额外经验假设，而是组成数据的规范化表示。因为对任意常数 c ,

$$(\beta + c\mathbf{1})^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}) = \beta^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}),$$

故只有系数之间的对比可识别；零和约束选取其中唯一的最小范数表示。当前实现先在精确归一化单纯形上拟合 Ridge，再将等价系数表示平移为零和形式，预测值保持不变。

由式 (1.11) 得到 1M 配比代理

$$\hat{L}_{k,1M}(\mathbf{p}) = \hat{\alpha}_k + \hat{\beta}_k^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (1.12)$$

定义相对参考配方的配比效应

$$m_k(\mathbf{p}) = \widehat{L}_{k,1M}(\mathbf{p}) - \widehat{L}_{k,1M}(\mathbf{p}_{\text{ref}}) = \widehat{\beta}_k^\top (\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (1.13)$$

因此 $m_k < 0$ 表示在 A4+A5 的 1M 目标域坐标上，代理预测的 Loss 低于参考配方； $m_k > 0$ 则相反。该量只属于 A 侧 1M 目标域 Loss 坐标，不自动具有 60M、1B 或附件 B 的 Loss 单位。

组成约束也给出系数的正确解释。若从训练域 r 向训练域 j 转移比例 δ ，即 $\mathbf{p}' = \mathbf{p} + \delta \mathbf{e}_j - \delta \mathbf{e}_r$ ，则线性代理给出

$$m_k(\mathbf{p}') - m_k(\mathbf{p}) = \delta(\widehat{\beta}_{k,j} - \widehat{\beta}_{k,r}). \quad (1.14)$$

因此可解释的是“两个域之间重新分配”的系数差，而不是单独提高某一域比例的因果效应。

1.3.2 13 维 Loss 向量与训练域-验证域作用矩阵

已有文献对多域 Loss 的标准处理并不是先把各域 Loss 压缩成一个标量，而是先逐验证域建模，再在决策层按任务需求聚合。Data Mixing Laws 将第 k 个验证域 Loss 写为训练配比的函数，并以训练域-验证域系数刻画跨域作用；BiMix 同样先保留逐域 Loss，再在配比约束下求解整体目标；DoReMi 则从最坏域 excess loss 出发构造鲁棒目标 [3, 4, 5]。本文不直接照搬这些论文的函数形式，而只采用与附件 A 数据结构一致的“逐维建模-向量决策”框架。

将 13 个逐域线性基线联立，定义

$$\widehat{L}_{1M}(\mathbf{p}) = \widehat{\alpha} + \mathbf{B}(\mathbf{p} - \mathbf{p}_{\text{ref}}), \quad \mathbf{B} = [\widehat{\beta}_{k,j}] \in \mathbb{R}^{13 \times 17}, \quad (1.15)$$

其中第 k 行对应一个验证域，第 j 列对应一个训练域。相对于参考配方的 13 维效应向量为

$$\mathbf{m}(\mathbf{p}) = \widehat{L}_{1M}(\mathbf{p}) - \widehat{L}_{1M}(\mathbf{p}_{\text{ref}}) = \mathbf{B}(\mathbf{p} - \mathbf{p}_{\text{ref}}). \quad (1.16)$$

因此 $\mathbf{B}$ 是本文线性代理下的训练域-验证域作用矩阵。需要强调的是， $\widehat{\beta}_{k,j}$ 本身仍是组成数据上的相对对比系数；严格可识别的两域重新分配效应仍由式 (1.14) 中的系数差给出。

为比较不同验证域的作用模式而不改变模型本身，热力图只对每一行作显示归一化

$$\widetilde{B}_{k,j} = \frac{\widehat{\beta}_{k,j}}{\max_r |\widehat{\beta}_{k,r}|}. \quad (1.17)$$

该归一化只用于可视化，不进入任何预测或优化计算。参照 Data Mixing Laws 对训练域–验证域作用矩阵的展示方式 [3]，本文的 $\tilde{\mathbf{B}}$ 只用于比较同一验证域内各训练域的相对作用模式；其数值来自本题 A4+A5 的 Ridge，而不是该文的指数混合律。




图 1.2 线性基线的 13 个验证域 $\times$ 17 个训练域行归一化作用矩阵。颜色表示 Ridge 相对对比系数的方向与相对强度；不能将单个格点解释为交互主模型的固定边际效应。

1.3.3 交互主模型与多目标配方决策

线性 Ridge 提供透明基线，但不能表达训练域之间的非加性关联。正式 Q1 配比预测改用每个目标域一个二阶交互代理。先在 A4 归一化配方上按方差选出五个训练域，从中构造十个二元乘积项；这一步不使用 Loss 标签。对第 k 个验证域，主模型写成

$$\hat{L}_{k,1M}^{\text{int}}(\mathbf{p}) = a_k + \sum_{j=1}^{17} b_{kj} p_j + \sum_{(u,v) \in \mathcal{E}} \gamma_{k,uv} p_u p_v, \quad |\mathcal{E}| = 10. \quad (1.18)$$

各目标域在 A4+A5 内以七个固定正则强度做五折选择，再用全部 512 条训练数据拟合。为了检验特征选择的乐观偏差，另做五折外层留出和五折内层选择：每个内层训练折重新选五个高方差域。交互模型的外层预测在 13/13 目标上取得比线性 Ridge 更低的 RMSE；目标域中位 RMSE 分别为 0.4499 与 0.4921，训练均值常数基线为 0.7790。真实 A6–A11 的同条件比较中，1M、60M、1B 分别有 11/13、13/13、13/13 个目标的交互 RMSE 较低。然而模型形式曾受前期检验观察影响，外部检验不构成全新盲测；1B 的绝对 Loss 误差仍大。

主接口输出的 A 侧配比效应为 $m_k^{\text{int}}(\mathbf{p}) = \hat{L}_{k,1M}^{\text{int}}(\mathbf{p}) - \hat{L}_{k,1M}^{\text{int}}(\mathbf{p}_{\text{ref}})$ 。用于多目标决策的无量纲分数为 $r_k(\mathbf{p}) = m_k^{\text{int}}(\mathbf{p}) / \hat{L}_{k,1M}^{\text{int}}(\mathbf{p}_{\text{ref}})$ ；分母是该交互模型自身的正参考 Loss，只服务于

A 侧目标加权，不是 B 侧 Loss 标定。交互项使边际效应随当前配方变化；可行的两域转移斜率为 $\partial_j \hat{L}_k^{\text{int}} - \partial_r \hat{L}_k^{\text{int}}$ ，单个 $\gamma_{k,uv}$ 的符号不具有独立因果解释。

主决策支持域是 A4 已观测配方的凸包 $\mathcal{P}_A = \text{conv}\{\mathbf{p}_1, \dots, \mathbf{p}_{512}\}$ 。给定明确的权重 $\mathbf{w} \in \Delta^{12}$ ，求解 $\min_{\mathbf{p} \in \mathcal{P}_A} \sum_k w_k r_k(\mathbf{p})$ ；保护最差域的情景求解 $\min_{\mathbf{p} \in \mathcal{P}_A} \max_{k:w_k>0} r_k(\mathbf{p})$ 。质量政策仅在 A16 direct 或 direct+near 映射域上要求覆盖份额及条件质量不低于参考配方，主值使用 A1 sample；其余 11 个域的 Q_A 保持未知。具体政策与权重由调用者显式声明。

二阶项使凸包内目标一般非凸，旧 Ridge 的线性规划顶点最优论证不再适用。本文将十个乘积项置于 McCormick 线性松弛中，对五个相关配比坐标做空间分支定界：每个节点的线性规划给出下界，其凸组合权重给出实际可行配方及上界。等权目标在无约束、direct、direct+near 三政策下的可行目标分别为 -0.11511、-0.10299、-0.09701；对应的全局下界分别为 -0.11607、-0.10343、-0.09776。最差域保护的无约束可行目标为 -0.01978、下界为 -0.02078。这四项数值上下界间隙均小于 0.001；它们是浮点线性规划的数值证据，不是严格区间算术证明。完整配方及节点数见 Q1 v2 数值结果文件 bounds.json。

为提供可直接使用的单条 A4 配方，另精确枚举 512 个已观测方案。在等权无约束、direct、direct+near 下分别选 index 136、301、172；最差域保护选 index 477，arxiv 单目标选 index 3。质量政策下连续凸组合明显改善有限集合目标，因此这些 index 只是备用离散方案；完整 45 个情景见 outputs/chm/q1_v2_decisions/。




图 1.3 交互主模型四个连续凸包情景的浮点数值上下界间隙；虚线对应预设的 0.001 容差。这是数值求解证据，不是严格区间证明。

任务没有给出 13 域的唯一外生权重，且等权 index 136 的未知质量域占比为 0.5686，故不宣称它在所有目标和完整质量口径下全局最优。进一步在 214 个权重情景上的先前稳定性审计显示模型和质量政策均可改变配方；该审计使用共同的旧 Ridge 参考 Loss 进行模型比较，不能与新接口的交互自身归一化结果混写。正式生产者 Q1 v2.0，接口清单已固定哈希。

为检查选方是否随训练数据变化，固定种子做 30 次无放回的 80% A4+A5 训练行子抽样，每次重选五个高方差域、逐目标五折选择正则并拟合交互模型，再在原 512 个已观测

候选中选方。上述四个原 index 分别保留 29、10、13、7 次。等权无质量约束的离散候选在此扰动下较稳定；两种质量政策和最差域保护的具体候选较敏感。因此推荐情景方案与约束口径，而不把一个 index 当成所有政策下的固定最优。此项只考察有限已观测候选，不能解释为连续凸包解的置信区间。

1.3.4 文献函数形式与本题主代理的关系

Data Mixing Laws 在固定模型规模与训练步数下采用

$$L_k(\mathbf{p}) = c_k + a_k \exp \left(\sum_{j=1}^{17} t_{k,j} p_j \right) \quad (1.19)$$

描述逐验证域 Loss[3]。本文的交互主模型与该式都保留 13 个验证域，但函数族不同。现有证据比较的是本文二阶交互与线性 Ridge；文献中的指数形式未在相同训练和检验协议下拟合，因此不宣称它优于或劣于当前主模型。

1.3.5 冻结代理后的跨实验组排序验证

问题一需要判断 A4+A5 学到的配方关系在附件提供的其他实验组中是否仍有信息。由于不同规模的绝对 Loss 水平明显变化，且附件 A 不提供与配方实验对应的 D ，验证指标采用只依赖排序的 Spearman 相关，而不拟合额外的尺度函数。对实验组 $\ell \in \{1M, 60M, 1B\}$ ，定义

$$\rho_{k,\ell}^{\text{pred}} = \rho_S \left(\widehat{L}_{k,1M}(\mathbf{p}_i^{(\ell)}), L_{ik}^{(\ell)} \right). \quad (1.20)$$

这里的 $\widehat{L}_{k,1M}$ 始终是由 A4+A5 冻结得到的同一代理；A6–A11 不参与系数拟合，但其比较结果参与了模型形式判断。

表 1.3 保留此前线性基线的排序结果；交互主模型在 1M、60M、1B 真实检验组的逐目标 Spearman 中位数分别为 0.8512、0.8474、0.7912，逐目标记录见 Q1 v2 验证表。两个模型在 1B 的配方支持与绝对 Loss 误差限制相同。

表 1.3 线性 Ridge 基线在 A6–A11 检验组的 13 个目标域配方排序相关；交互主模型结果见正文

实验组	中位 Spearman	均值	最小值	最大值
1M	0.8381	0.8328	0.7446	0.9227
60M	0.8381	0.8314	0.7521	0.9202
1B	0.7067	0.7285	0.5691	0.8876

A6 与 A8 使用完全相同的 256 条配方，因此还可以不依赖任何代理，直接比较两个实验组的真实 Loss 排序：

$$\rho_k^{1M \leftrightarrow 60M} = \rho_S \left(L_k^{1M}(\mathbf{p}_i), L_k^{60M}(\mathbf{p}_i) \right). \quad (1.21)$$




图 1.4 线性 Ridge 基线在三个真实检验组上的逐目标域排序表现。1B 使用不同的配方集合，因此其变化不能解释为纯参数规模效应。

13 个目标域的相关范围为 0.9801–0.9980，中位数为 0.9944，见图 1.5。这只能说明在题目给定的这两组实验条件下，同一批配方的相对优劣高度稳定；由于 A 数据没有对应的 D 等训练控制变量，本文不把这种差异单独归因于参数量 N 。




图 1.5 相同 256 条配方在 1M 与 60M 两个真实实验组中的 Loss 排序稳定性。

A10 的 64 个 1B 配方与 A4/A6 的配方集合没有完全重复，因此 1B 的式 (1.20) 属于未见配方集合上的外部排序检验。它可以支持“1M 学到的配比排序仍保留部分信息”，但不能支持连续的 N 尺度传递。几何支持审计进一步显示，A10 的 64 个配方只有 17 个位于 A4 训练凸包内，47 个位于凸包外。因此 1B 汇总指标还混有配方支持域外推，不能仅解释为模型规模变化；正文中的任何“跨规模验证”均应同时注明这一点。

1.3.6 绝对 Loss 迁移的反证性诊断

若直接把 A4+A5 的 1M 代理当作其他实验组的绝对 Loss 预测器，则尺度平移会显著影响 RMSE。删除全部配比变量、只使用 A4+A5 中该目标域的常数均值作为基线时，1M、60M、1B 的 13 域 RMSE 中位数分别为 0.6759、1.4724、3.2514；完整 Ridge 分别为 0.4478、1.4450、3.2079。完整模型在 1M 和 60M 上分别有 13/13 个目标域的 RMSE 下降，但到 1B 只有 4/13 个目标域下降。




图 1.6 冻结 1M 配比代理相对于无配比常数基线的 RMSE 诊断。该图用于说明绝对 Loss 不能由附件 A 直接跨规模搬运，而非构造尺度律。

因此第一问的可验证结论是“冻结 1M 配比代理在 A6–A11 的实验组保留一定排序信息”，而不是“1M Loss 幅度或排序能够可靠外推到任意大模型”。原先利用三个离散实验组拟合 $b_k(N)$ 和公共衰减指数 η 的做法不再进入主模型：A 数据既没有与配方实验对应的 D ，又只有三个模型规模位置，且 1B 的配方支持集与 1M/60M 不同，无法把斜率变化唯一归因于 N 。

正式交互主模型的 A4+A5 特征选择、逐目标拟合与决策见式 (1.18)。它在真实 A6–A11 三个检验组的绝对 RMSE 分别在 11/13、13/13、13/13 个目标上低于线性 Ridge；但 1B 组仍只有 11/13 个目标优于 A4 训练均值常数基线。乘积系数的符号只是所选组成基底下的拟合关联；在单纯形上增加两域比例还须从其他域移走质量，故不得将其解释为因果协同或可直接转移至 B7 的性能增益。正式 Q1 配比生产者 `chm.q1.v2.0`。

为在不查看 A6–A11 的条件下比较模型族，我们另做 A4+A5 五折外层留出、五折内层选正则；交互的五个域在每个内层训练折和外层训练折重选。512 条外层预测中，交互对 13/13 目标的 RMSE 均低于 Ridge 与外层训练均值基线，目标域中位 RMSE 为交互 0.4499、Ridge 0.4921、常数 0.7790。真实 1B 检验若按 A4 凸包拆为 17 条内、47 条外，交互在两组分别对 13/13 目标降低 RMSE；但排序相关在整个 1B 组仅 7/13 目标高于 Ridge。按 214 组目标权重在 1B 的 17 条域内候选上模拟候选集内部选择，交互的实际遗憾中位数为 0.1597、Ridge 为 0.1924，前十分位命中率却分别为 32.7% 与 33.6%。因此“预测误差较小”不等同于“每种决策准则均较好”；交互形式也曾在前期检验后被研究，现有外测不再是一套完全未触碰的最终测试。完整逐目标指标、支持域分组和选方压力记录于本人实验台账。

1.3.7 A12–A15 的使用边界

A12–A15 的 10B/70B Loss 在数据说明中明确标记为 estimated/extrapolated，因此既不参与交互主模型或 Ridge 基线的拟合，也不参与模型选择。两组使用相同的 63 个配方，且均为 A4 已见配方。附件给出的 10B 与 70B 估算 Loss 在 13 个目标域中的直接 Spearman 中位数为 0.9907，说明两张估算表彼此排序接近；但冻结 v2 交互模型与两张估算表的逐目标 Spearman 中位数分别只有 0.4915、0.3941，Ridge 对照为 0.5136、0.4148。交互主模型在两组中分别只有 5/13 个目标的排序相关高于 Ridge。

作为候选内部的决策压力测试，对每组 63 个候选的 13 域 Loss 按各域本组均值中心化并除以正均值后等权平均。v2 与 Ridge 都选择 index 16，而其估算分数在两组均排第 61/63；10B 和 70B 估算表的最优 index 分别为 45、32。由此可见，A6–A11 的模型误差改善不能推出估算大规模时的配方排序稳健。以上只是对题目估算表的负向压力证据，不是 10B/70B 实测训练验证，也不能据此回头调整已冻结主模型。




图 1.7 冻结交互主模型在真实检验组与估算外推表上的 13 目标域排序相关。虚线左侧为 A6–A11 真实实验组，右侧为 A12–A15 估算 Loss；两类证据不可混作同一验证。

1.4 Q1 向后续问题的严格接口

A16 中仅有 3 个 direct、3 个 near-direct 域映射，其余 11 个为 inferred，因此本文不生成 17 个看似精确的质量真值。第一问正式交付如下：

1. 七个质量域的 A 侧综合质量代理 Q_A 、条件抽样区间及评分规则敏感性。 Q_A 是描述性复合指标，不等于附件 B6–B8 的原生 Q_{score} 。
2. 17 维配比的 13 个目标域 1M 二阶交互代理，以及式 (1.18) 定义的 target-specific 相对配比效应 $m_k^{\text{int}}(\mathbf{p})$ ；线性 Ridge 作为基线保留。
3. A6–A11 给出的跨实验组排序验证和 A12–A15 的 estimated/extrapolated 压力测试。

下游条件复算显式固定 Q1 v2.0 的交互系数与参考 Loss、cyj 的 B7 参数以及 $\lambda = 1, \eta = 0$ ；在 $N = 1\text{B}$ 、 $D = 100\text{B}$ 、 $Q_B = 0.5$ 、13 域等权条件下，三种质量政策的连续凸包可行配方对应条件 B7 Loss 约为 2.271859、2.302976、2.318334。它们附有 Q1 目标的数值上下界，详见 outputs/chm/q2_interaction_scenarios_v2/；此项是 chm 侧按固定 cym 参数的重算，cyj 的正式新版消费仍需显式锁定 v2.0 清单哈希。Q3 的 A 侧配方诊断已消费 v2.0，旧 Q3 结果不自动继承新版配方数值。

附件 A 没有提供 $Q_A \leftrightarrow Q_{\text{score}}$ 的成对标定样本，也没有证明任一 Q1 目标域 Loss 与 B1 的 val_loss 属于同一数值坐标。因此第一问不提供 $Q_A \rightarrow Q_{\text{score}}$ 的数值映射，不把 $m_k(\mathbf{p})$ 直接加到 B1 Loss，也不提供由 A 数据拟合的 η 、 $b_k(N)$ 或其他连续尺度传递参数。具体地，问题二条件情景中的桥接形式 $L_B = L_{B7}[1 + \lambda(N/1\text{B})^{-\eta} \sum_k w_k m_k(\mathbf{p})/L_{A,k,\text{ref}}]$ 在参考配方满足 $m_k(\mathbf{p}_{\text{ref}}) = 0$ ；因此任意 λ, η 都复现同一 B 侧基线，单一 $N = 1\text{B}$ 情景又使 η 消失。缺少配方与 B 侧同条件 Loss 的成对观测时，这两个桥接参数不可从现有附件识别。 N 、 D 、B-native Q 与 Loss 的统一关系由问题二依据附件 B 独立建立；若后续需要把 $m_k(\mathbf{p})$ 映射到 B 侧 Loss，必须额外给出可验证的 Loss 坐标桥接证据。

1.5 本问结论与局限

在题目附件能够直接识别的范围内，问题一得到三点结论。第一，22 维质量信号可以构造透明的 A 侧综合质量代理，但其数值依赖明确的方向和权重假设，不能解释为客观质量真值；A2/A3 的非重叠记录支持 arxiv/github 域级结论在扩展样本上的稳定性，且多数负相关指标对在完整扩展与去重扩展中保持同号。第二，A4+A5 的逐目标域二阶交互主模型在训练内嵌套验证和真实检验的预测误差上多数优于线性基线；给定权重与质量政策时，A4 凸包内四个情景均获得间隙小于 0.001 的数值界。第三，A12–A15 的估算压力结果和重拟合选方诊断揭示跨规模排序及具体配方的有效范围，附件 A 不足以单独建立连续的配比尺度律。

因此，本问只输出“质量代理、配比相对效应、排序验证和映射边界”，把 N 、 D 与 B-native 质量坐标上的广义 Loss 建模严格留给问题二，从而使四问之间的递进关系与题目

提供的数据保持一致。

参考文献

- [1] OpenDataLab, SlimPajama-Meta-rater Dataset Card.
- [2] Liu Q, Zheng X, Muennighoff N, et al., RegMix: Data Mixture as Regression for Language Model Pre-training, International Conference on Learning Representations, 2025.
- [3] Ye J, Liu P, Sun T, et al., Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance, International Conference on Learning Representations, 2025.
- [4] Ge C, Ma Z, Chen D, et al., BiMix: A Bivariate Data Mixing Law for Language Model Pretraining, 2025.
- [5] Xie S M, Pham H, Dong X, et al., DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining, Advances in Neural Information Processing Systems, 2023.